PRUEBA TÉCNICA · DATA SCIENCE · RETAIL EN MÉXICO

Pronóstico de demanda para reposición, con capa de agentes

¿Cuánto reponer por tienda y categoría cada semana, y con qué evidencia?

80 tiendas · 6 categorías · 425 días · 480 series diarias

El problema que elegí

La pregunta de negocio

¿Cuánto reponer por tienda × categoría cada semana?

Por qué esa y no otra

- Es la única con un **sistema actual** contra el cual medir valor (`replenishment_signal`).
- Las promociones se asignaron **al azar**: eso permite medir causalidad, no solo correlación.
- Otras opciones (tráfico, efectivo) no tenían señal o tenían datos inconsistentes.

Los datos

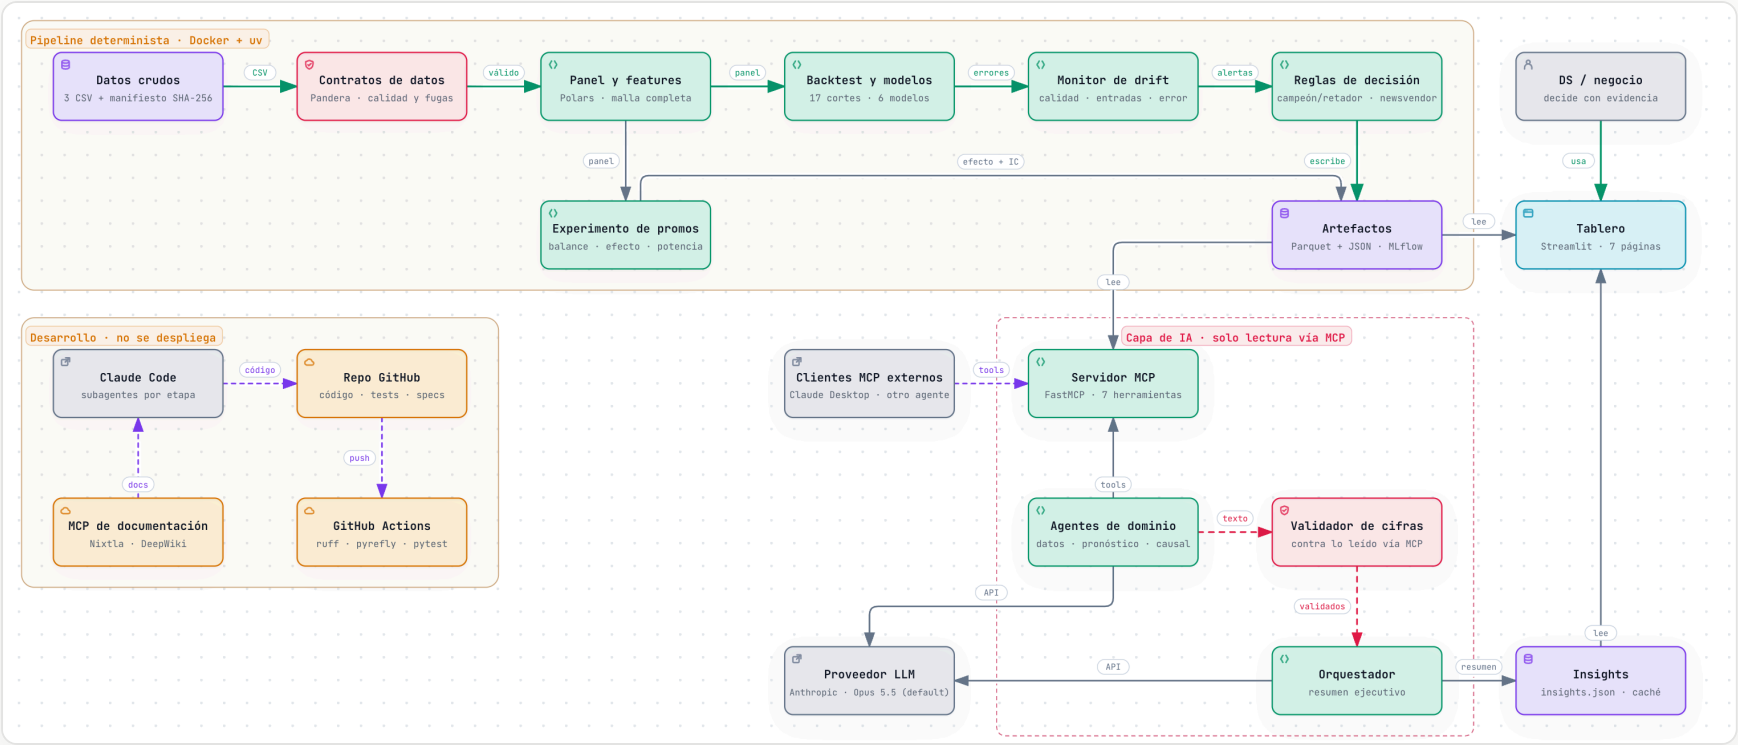
Tabla	Grano
`transactions`	fecha × tienda × categoría (~204 k filas)
`stores`	80 tiendas: formato, región, NSE, tamaño
`calendar`	425 días: festivos, Buen Fin, quincenas

Los datos nunca se suben al repo: se colocan con `make data` y se verifican contra un manifiesto SHA-256.

Seis preguntas, seis respuestas

Pregunta	Respuesta
¿El sistema actual es honesto?	**No del todo:** su señal mira un día al futuro. Sin la fuga, su WAPE semanal sube de 18.6 a **20.1 %**
¿Un modelo nuevo es mejor?	**Todavía no se puede afirmar:** LightGBM baja el WAPE de 27.3 a 20.3 %, pero p = 0.17 con 17 cortes
¿Dónde está el valor?	**En la regla de decisión:** el newsvendor cuesta **40 % menos** (p = 0.019); LightGBM agrega 9 %, sin significancia
¿El monitor de drift funciona?	**Sí, con un límite:** detecta los 3 escenarios inyectados y una falla real, pero confunde la estacionalidad anual
¿Las promociones venden más?	**No:** +0.05 % (IC95 −0.25 a +0.34 %). Solo Bebidas responde, y ningún descuento se paga
¿Hay algo raro en los datos?	**Sí:** el 20 % de «conteos inconsistentes» son exactamente los días con promoción

La solución, de punta a punta



Pipeline determinista: todo lo que calcula o decide es código con pruebas. Un comando: `make pipeline`.

Capa de IA: los agentes leen por MCP, no calculan ni eligen el modelo, y cada cifra pasa por un validador.

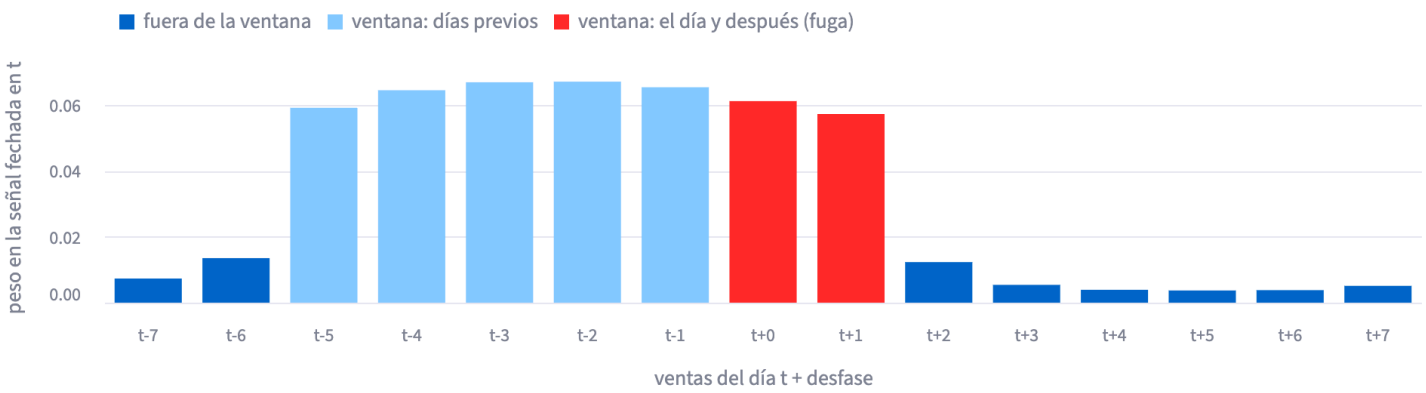
Desarrollo: Claude Code construyó el repo; nada del producto depende de él.

1 · DATOS

Antes de modelar, auditar

La señal del sistema actual mira al futuro

Tablero › Datos



Consecuencia: con origen T solo se pueden usar valores de la señal fechados en **T−1 o antes**. Medido así, el sistema actual tiene un WAPE semanal de **20.1 %**, no 18.6 %. Esa es la vara honesta.

- El diccionario no lo menciona. Lo descubrió la prueba de fuga de E1: una regresión de la señal sobre las ventas de t−7 a t+7 concentra el peso de t−5 a t+1 (correlación intraserie 0.95).
- El backtest lo impone por construcción: cada modelo recibe solo `historia` (≤ T, con la señal de T en nulo) y `futuro` (calendario, tienda y promoción).

Otros hallazgos de calidad

Conteos inconsistentes = días de promoción

En ~20 % de las filas, `cash + card < total_transactions`. Son exactamente los días con promoción: `total_transactions` vale 1.22 × los pagos, y el exceso son registros sin pago. Lo encontró el experimento de E6.

Solo 42 filas faltan

El panel es la malla completa (204,000 filas) con las faltantes marcadas. Así un `shift` por serie siempre equivale a días de calendario. Nada se imputa.

Calendario fuerte y multiplicativo

Buen Fin ×2.65, fin de semana ×1.53, quincena ×1.38 y Semana Santa ×0.66, casi igual en todas las categorías. Buen Fin y Semana Santa ocurren una sola vez.

Contratos que no mienten

El contrato exige solo lo que siempre debe cumplirse (tipos, llaves, montos que cuadran). Los problemas conocidos se miden y se marcan, no rompen el pipeline.

2 · PRONÓSTICO

¿Un modelo nuevo le gana al sistema actual?

El protocolo, fijado antes de ver resultados

17 cortes semanales

Los jueves del 2023-11-02 al 2024-02-22, con horizonte de 7 días. Cubren Buen Fin, Navidad y enero–febrero.

Métrica: WAPE de la suma semanal

Es la granularidad de la reposición. Medido por día, el sistema actual (una media de 7 días) quedaría castigado injustamente: 45.7 %.

Prueba de fugas

Todo modelo registrado pasa una prueba que altera el futuro y exige el mismo pronóstico.

6 modelos

El sistema actual sin fuga, naive estacional, MA7, AutoETS, LightGBM global por cuantiles y Chronos-2 sin entrenar.

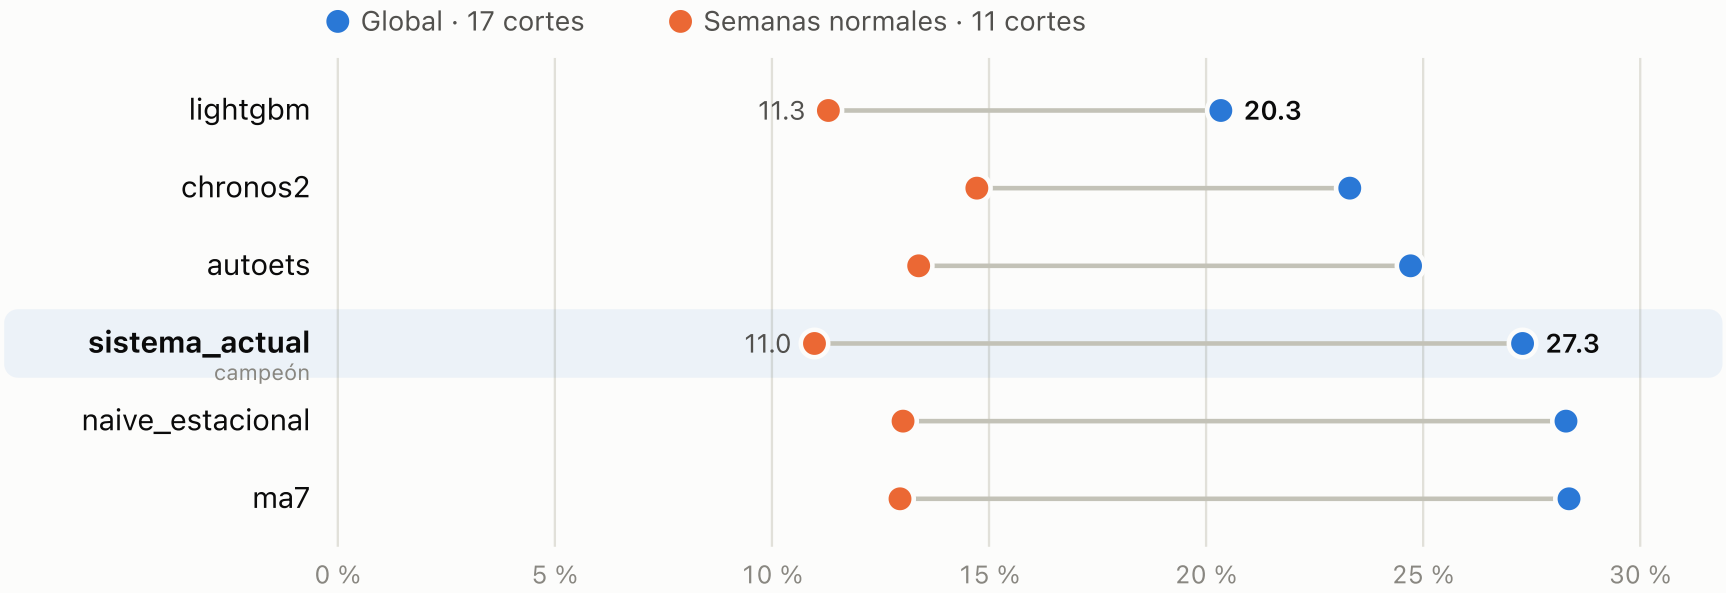
Regla de campeón pre-registrada

Para cambiar de modelo: menor WAPE, Diebold-Mariano significativo y sin sesgo excesivo en ningún segmento.

Ajuste fuera del backtest

Los hiperparámetros de LightGBM salen de orígenes previos al primer corte. Nunca se ajusta con los cortes que se evalúan.

LightGBM gana en el global; en semanas normales, empate



La ventaja de LightGBM viene de **tres semanas excepcionales** (la posterior al Buen Fin y las dos de fin de año). Con 17 cortes, la Diebold-Mariano da **p = 0.17**: la regla mantiene al **sistema actual como campeón** y deja a LightGBM como retador en vigilancia.

El sistema actual falla en los picos, no en lo normal

11.0 %
WAPE del sistema actual en semanas normales: el mejor de los seis

−50 %
su sesgo en el Buen Fin: pide la mitad

+101 %
su sesgo la semana siguiente: su señal promedia el pico y pide el doble

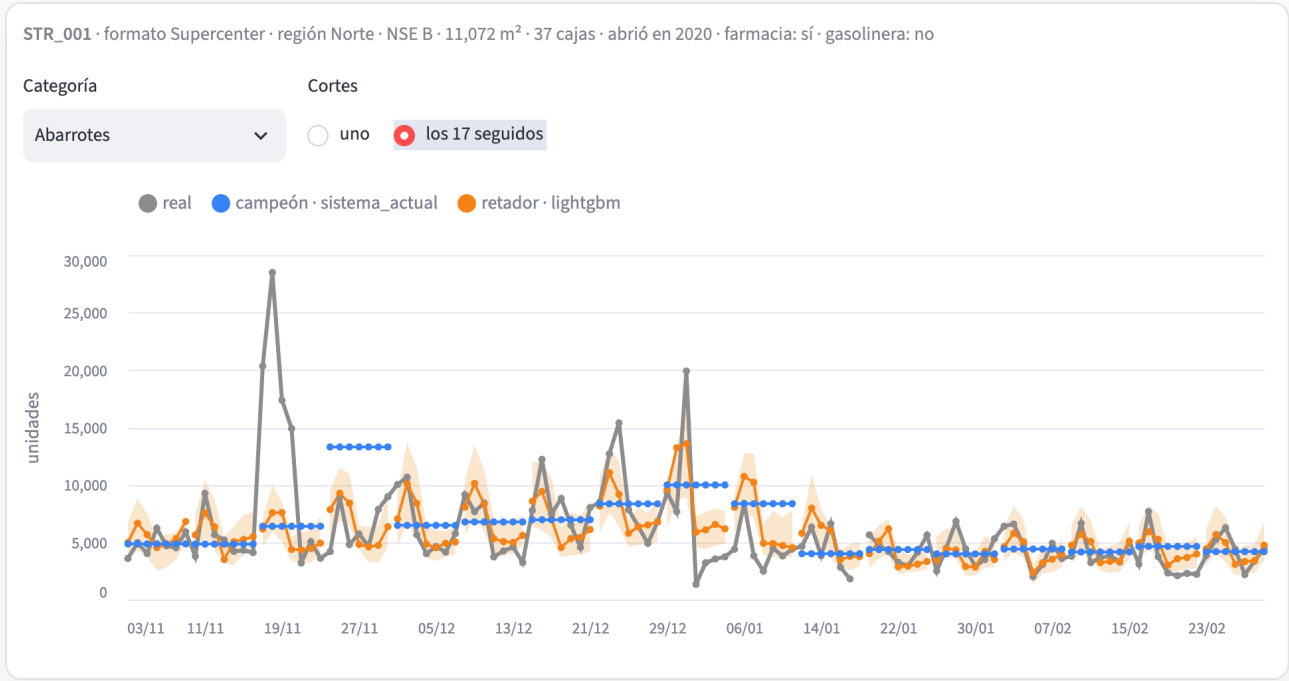
Chronos-2 (sin entrenar, con covariables): 23.3 % global, con un sesgo de −14 %.

Los intervalos del 80 % de LightGBM y Chronos-2 cubren solo el 67–69 %. Por eso la decisión no se apoya en ellos, sino en los errores empíricos.

Lo que enseñó: fijar la regla antes de ver resultados importó. Siete puntos de mejora son tentadores, pero no se distinguen del ruido con 17 semanas. Harían falta ~34.

Una tienda, los 17 cortes

Tablero › Pronóstico



Abarrotes en `STR_001`. El campeón (azul) es plano dentro de cada semana: no ve el Buen Fin, y la semana siguiente su pronóstico sube a más del doble cuando la venta ya bajó. LightGBM (naranja) sigue el perfil semanal, pero tampoco anticipa el pico. En el tablero se elige cualquier tienda y categoría.

Dónde falla cada modelo

Tablero › Modelos

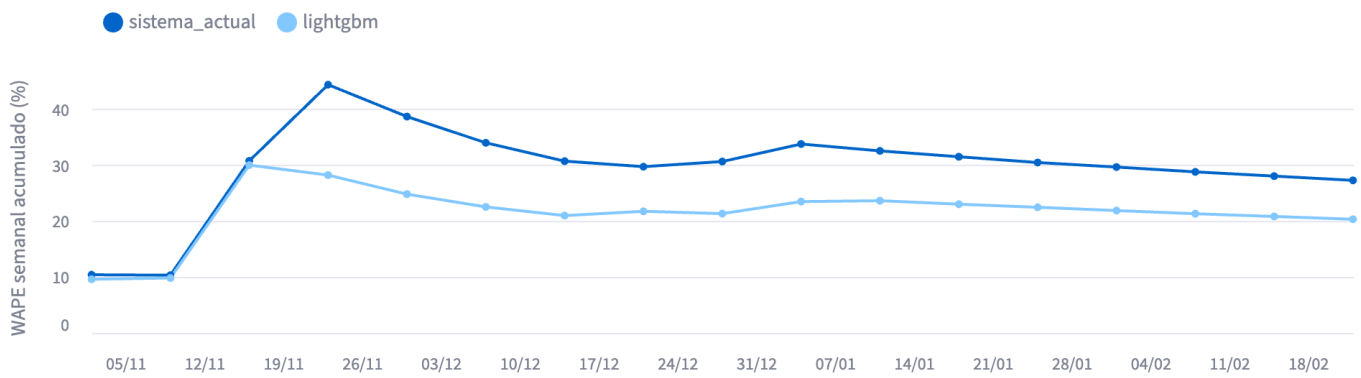


Buen Fin: los seis modelos piden la mitad (sesgo de −49 a −55 %). Ninguno puede aprenderlo: ocurre una sola vez en los datos.

La semana siguiente: los que promedian lo reciente (sistema actual, naive y MA7) piden casi el doble, +95 a +101 %. LightGBM falla 21 % y Chronos-2, 13 %.

El retador queda en vigilancia

Tablero › Decisión y drift



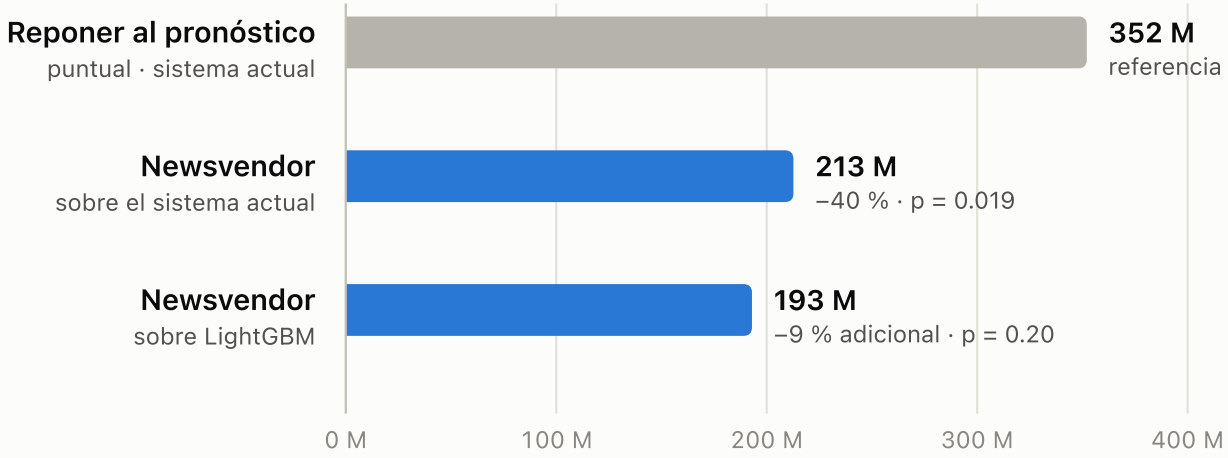
DM acumulada al último corte	p mínima en el backtest	Umbral con Bonferroni	Cortes necesarios estimados
p = 0.166	p = 0.138	p < 0.00294	34

WAPE semanal acumulado al cerrar cada corte. La brecha se abre la semana después del Buen Fin y ya no se cierra, pero la Diebold-Mariano acumulada termina en **p = 0.166**. Como se revisa cada semana, el umbral lleva Bonferroni (0.05 / 17), y se estiman **34 cortes** para poder decidir. El monitor lo repite en cada corte, sin intervención.

3 · DECISIÓN Y DRIFT

Del pronóstico a cuánto pedir

La decisión pesa más que el modelo



Newsvendor por categoría: el nivel objetivo es S = Σŷ × q, con q el cuantil de los errores pasados en la fracción crítica.

Los quiebres bajan de 12.8 a 5.6 % de la demanda. El costo está en los eventos: el Buen Fin pesa **114 de los 213 M**.

En semanas normales, LightGBM y el sistema actual empatan. Los márgenes y costos de mantener son supuestos ilustrativos; el precio sale de los datos.

Un monitor de drift en tres capas

Calidad

Nulos, filas faltantes y conteos. Detectó la falla real de captura de `STR_055`.

Entradas

Nivel de demanda, tasa de promoción, ticket y mezcla de calendario. Separa lo **esperado por calendario** de lo inesperado.

Desempeño

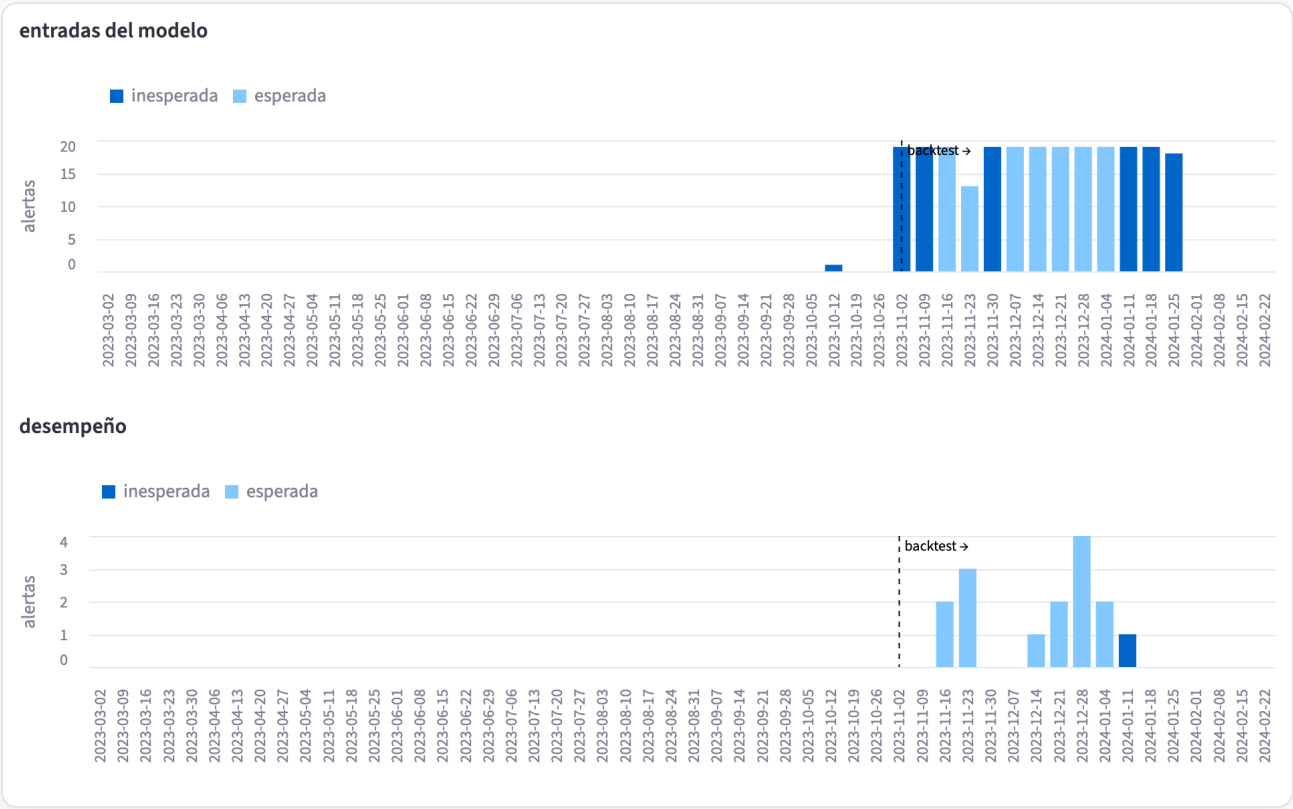
El WAPE semanal del campeón contra su banda, y la vigilancia del retador. Cada alerta trae una recomendación.

Validado con drift inyectado: una falla de POS en una tienda, un salto de +30 % en una región y un cambio en la tasa de promoción. Detecta los tres, y en un panel sintético limpio no da alertas inesperadas.

Límite declarado: su referencia de 56 días no distingue la estacionalidad anual, y alerta en todos los segmentos en noviembre y enero. Se documentó; no se ajustó mirando esas semanas.

Las alertas, semana a semana

Tablero › Decisión y drift



Entradas: desde el primer corte alertan casi todos los segmentos. En las semanas con evento son esperadas; en noviembre y enero salen inesperadas. Es el límite de la referencia de 56 días.

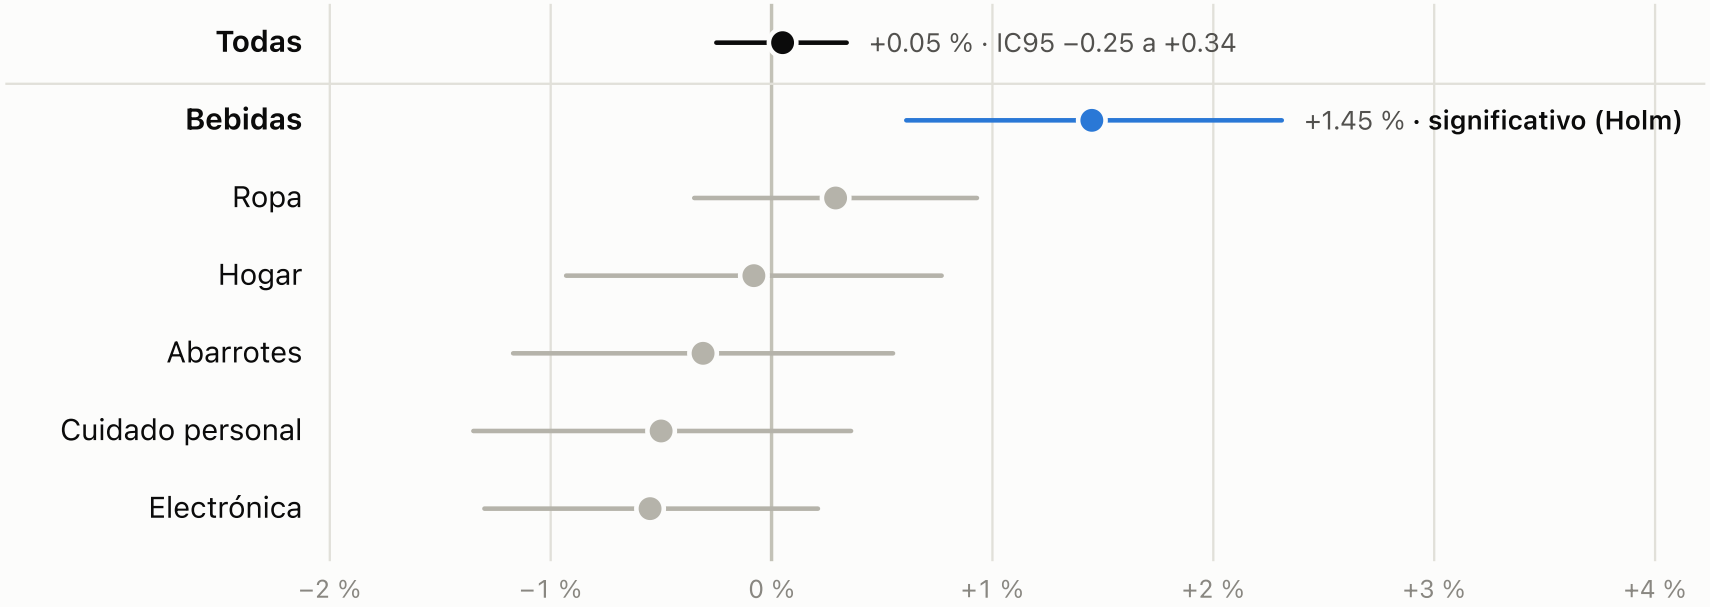
Desempeño: 15 alertas en el backtest, 14 esperadas por evento. La única inesperada es del retador, la semana del 11 de enero.

Arriba de estas dos va la capa de calidad: 5 alertas en 52 semanas.

4 · PROMOCIONES

Un experimento natural

Las promociones no mueven las unidades

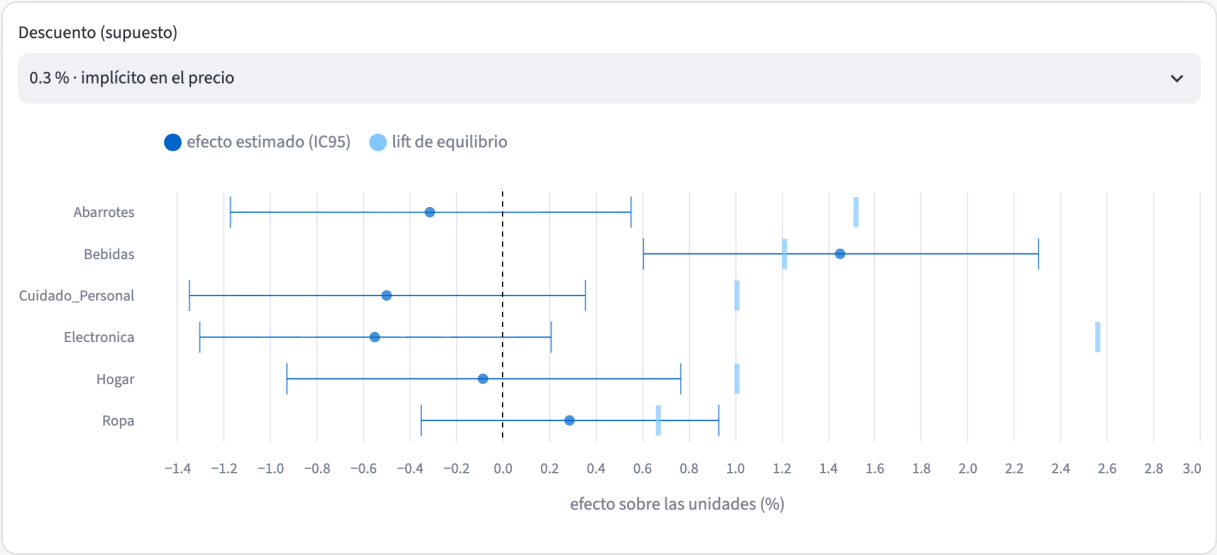


Método: log-OLS con efectos fijos de serie y de fecha, errores agrupados por tienda, inferencia por aleatorización (2000 permutaciones), calibración A/A y Holm por familias.

Un nulo preciso: el diseño detecta efectos de 0.42 %. Con márgenes supuestos, **ningún descuento de 5 a 20 % se paga**, ni siquiera en Bebidas.

¿Alguna categoría se paga?

Tablero › Promociones



El **lift de equilibrio** (barra clara) es el aumento de unidades con el que la promoción apenas se paga, con el margen y el descuento supuestos. El selector cambia el descuento.

Con el descuento implícito en el precio (0.3 %), Bebidas y Ropa quedan indeterminadas y el resto no se paga. Con 5 a 20 %, **ninguna se paga**.

El experimento también auditó los datos

La bandera más rara del dataset era la huella de la promoción.

- En los días con promoción, `total_transactions` sube **22 %**...
- ...pero no cambian los pagos, ni las unidades, ni el monto.
- El exceso son **registros sin pago**.
- Consecuencia: el ticket correcto es `amount_total / (cash + card)`. Usar `total_transactions` lo subestima ~18 % esos días.

Lo honesto: una regla pre-registrada que falló

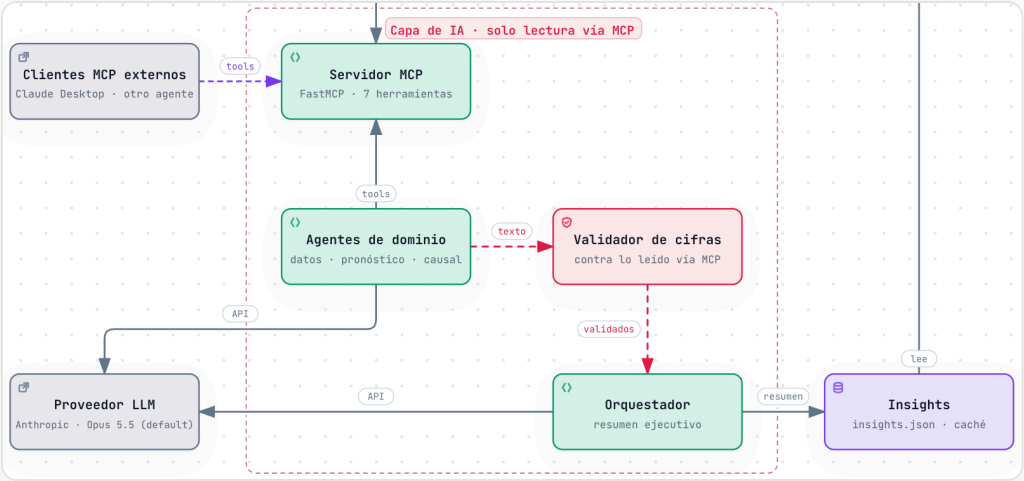
> La prueba de balance pre-registrada falló, solo por esa bandera, que es un **resultado** de la promoción y no una covariable. Las pruebas de la asignación pasan todas.
>
> La separación entre asignación y medición se decidió **después** de ver los datos, y está declarada así en el código, la spec y el JSON.

El próximo A/B propuesto: 4 brazos por tienda × categoría × semana, en bloques de formato × región, durante 8 semanas.

5 · CAPA DE AGENTES

Agentes que interpretan, no deciden

Arquitectura de la capa de agentes



- **Pydantic AI**, agnóstico de proveedor. Por omisión Claude Opus 5.5; con `LLM_MODEL`, OpenRouter o cualquier gateway compatible con OpenAI.
- **El servidor MCP** también sirve a clientes externos, por stdio o HTTP.

Validador de cifras

Una cifra solo pasa si aparece en lo que el agente leyó de las herramientas **en esa corrida**. Si falla, reintenta; si vuelve a fallar, usa una plantilla.

Tres modos

En vivo con key. Sin key, una **caché versionada**, válida solo si coinciden la huella de los artefactos y la versión del prompt. Si no, plantillas deterministas.

Costo acotado

~USD 0.44 y ~2 min por corrida, con un freno de USD 1 por corrida y uno de USD 20 acumulados.

Lo que concluyen los agentes

1 · Mantener el sistema actual

Como pronóstico oficial, y medirlo contra la referencia correcta (sin la fuga).

2 · El beneficio está en cómo se pide

No en cambiar de modelo: el colchón calibrado baja el costo y los quiebres.

3 · Las promociones no venden más

El aumento de tráfico es un error de registro, no demanda.

4 · Buen Fin necesita plan manual

Y el monitor no debe disparar reentrenamientos por estacionalidad.

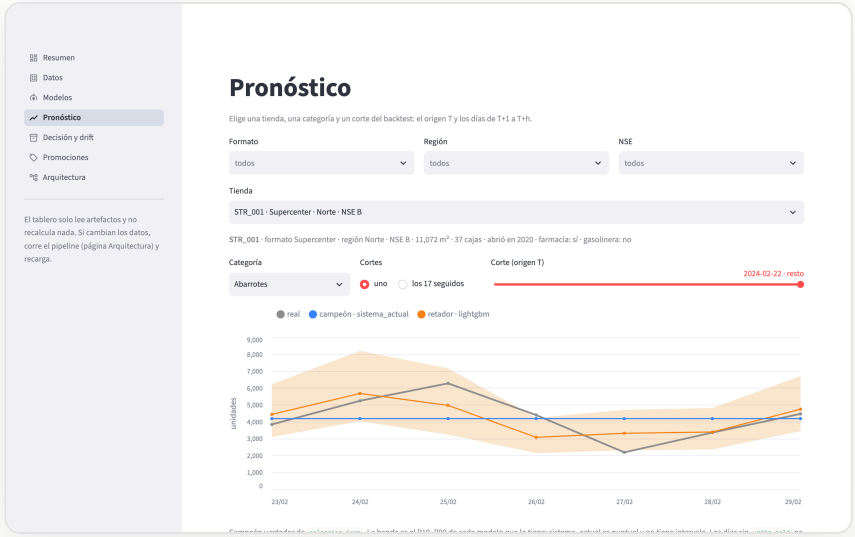
183 cifras revisadas por el validador, ninguna rechazada. Un script independiente encontró en los artefactos los 161 números del texto.

Límite medido: el validador comprueba que la cifra exista, no que la frase la use bien. Una cifra inventada con un decimal pasa el 13–15 % de las veces por coincidencia. Por eso también se lee el texto.

El tablero



Resumen: indicadores y conclusiones del orquestador, con su estado de validación.



Pronóstico por tienda × categoría: real, campeón y retador con su banda P10–P90.

Streamlit, 7 páginas: resumen, datos, modelos, pronóstico, decisión y drift, promociones y arquitectura. **Solo lee artefactos**: no recalcula nada. Las capturas con la etiqueta «Tablero» salen de él. Se levanta con `make app` o `docker compose up app`.

6 · PROCESO

Cómo se trabajó con IA

Un ciclo por etapa, con verificación independiente

1

Spec pre-registrada

Método, umbrales y reglas de conclusión, escritos **antes** de correr nada.

2

Implementación

Un agente con instrucciones de rol (`.claude/agents/`). Los desvíos quedan en la spec.

3

Verificación

Scripts propios escritos desde la spec, sin el código del agente. En E6, con otra librería (pyfixest).

4

Revisión con mutaciones

Otro agente rompe el código a propósito. Si las pruebas siguen pasando, faltan pruebas.

Etapa	Mutaciones que sobrevivían	Después de los arreglos
E5 · decisión y drift	16 de 42	mueren 48 de 50
E6 · promociones	22 de 41	mueren 41 de 44
E7 · agentes	18 de 45	mueren 49 de 51
E8 · tablero	19 de 35	mueren las 34 que aplican

Bugs reales que atrapó la revisión:

- el validador dejaba pasar «15,7 %» como «15»;
- la potencia del A/B semanal, extrapolada, daba cifras imposibles;
- la imagen Docker copiaba un caché con salidas del EDA;
- `MLFLOW_TRACKING_URI` del shell podía mandar runs a un servidor remoto.

Reproducible por dos rutas

```
make setup
make data DATA_SRC="ruta/al/zip"
make pipeline        # ~25–35 min
make app             # :8501
```

```
docker compose build
docker compose run --rm pipeline   # ~40 min
docker compose up app mcp mlflow
```

Ensayo en limpio con dos clones nuevos, siguiendo el README al pie de la letra:

- **macOS (uv):** los 9 artefactos salen **idénticos byte a byte** a los del repo de desarrollo.
- **Linux (Docker):** las mismas cifras, y la caché de insights sigue valiendo entre plataformas.

CI: lint, tipos, 451 pruebas sin datos reales, gitleaks sobre el historial, `docker build` y una prueba de humo del pipeline completo sobre 40 tiendas sintéticas (~1 min).

Límites, dichos en voz alta

- **Buen Fin y Semana Santa ocurren una sola vez**: su efecto no se valida fuera de muestra.
- **17 cortes** no bastan para afirmar que LightGBM es mejor; harían falta ~34.
- **Los intervalos** del 80 % cubren solo el 67–69 %.
- **Los costos** del newsvendor son supuestos, no datos.
- **Ventas ≠ demanda**: los quiebres no se observan.
- **Los datos parecen sintéticos**: aleatorización perfecta y un calendario casi idéntico por categoría.
- **El monitor** confunde la estacionalidad anual con drift.
- **El validador** comprueba la cifra, no la interpretación.
- **Chronos-2** necesita red la primera vez.
- **La imagen** pesa 3.4 GB, sobre todo por torch.

Para llevarlo a producción

Secretos

Secret Manager con Workload Identity, sin llaves JSON; GitHub → GCP por OIDC; el LLM vía un gateway corporativo.

Datos

GCS con versionado de objetos y el mismo manifiesto de hashes; DVC como opción.

Escala

PySpark en Dataproc o BigQuery para llegar a SKU; entrenamiento distribuido del modelo global.

Operación

Corrida semanal agendada, registro de modelos en MLflow, el monitor como job con alertas y el MCP detrás de autenticación.

Siguiente paso de negocio: correr el A/B de promociones de 8 semanas y acumular cortes. Con ~34 semanas, la misma regla, sin tocarla, vuelve a decidir con más evidencia.

Gracias

El detalle de cada etapa (lo pre-registrado, los cambios al implementar y el resultado) está en `docs/specs/`.

github.com/javier-laguna/demanda-reposicion